


Plano do Minicurso

- 1 Introdução
- 2 Linux e shell
- 3 Banco de Dados
- 4 Montagem de genoma
- 5 Anotação
- 6 Filogenia Molecular



Introdução LINUX e SHELL para Bioinformática

Minicurso de Introdução à Bioinformática
Escola Paranaense de Bioinformática 2022 UFPR

CAMILA P PERICO

Bióloga pela UFPR
Mestre e Doutoranda do Programa de Pós-Graduação em Bioinformática
Universidade Federal do Paraná

6 de agosto de 2022




Linux

Porque usar Linux?

Além de ser gratuito, livre e possuir várias distribuições para cada tipo de usuário, a maioria das ferramentas de (e não apenas de) bioinformática possuem versões gratuitas para Linux.

Apesar do Windows possuir várias vantagens e popularidade, o Linux se destaca no desenvolvimento e análise de dados por possuir liberdade, praticidade e grande poder computacional.



Shell

Interface que permite acesso em linhas de comando ao Sistema Operacional (SO).

Também conhecido como: prompt, terminal, console, tela preta.

O shell é equivalente ao prompt de comando e ao Powershell do Windows.

```
vivek@nixcraft:/tmp$ vi hello.sh
vivek@nixcraft:/tmp$
vivek@nixcraft:/tmp$ chmod +x hello.sh
vivek@nixcraft:/tmp$
vivek@nixcraft:/tmp$ ls -l hello.sh
-rwxr-xr-x 1 vivek vivek 31 Jan 21 15:08 hello.sh
vivek@nixcraft:/tmp$
vivek@nixcraft:/tmp$ ./hello.sh
Hello World
vivek@nixcraft:/tmp$
vivek@nixcraft:/tmp$ bash hello.sh
Hello World
vivek@nixcraft:/tmp$
vivek@nixcraft:/tmp$ sh hello.sh
Hello World
vivek@nixcraft:/tmp$ cat hello.sh
#!/bin/bash
echo "Hello World"
vivek@nixcraft:/tmp$
```

Shell

Interface que permite acesso em linhas de comando ao Sistema Operacional (SO).

Também conhecido como: prompt, terminal, console, tela preta.

O shell é equivalente ao prompt de comando e ao Powershell do Windows.

```
vivek@nixcraft:/tmp$ vi hello.sh
vivek@nixcraft:/tmp$
vivek@nixcraft:/tmp$ chmod +x hello.sh
vivek@nixcraft:/tmp$
vivek@nixcraft:/tmp$ ls -l hello.sh
-rwxr-xr-x 1 vivek vivek 31 Jan 21 15:08 hello.sh
vivek@nixcraft:/tmp$
vivek@nixcraft:/tmp$ ./hello.sh
Hello World
vivek@nixcraft:/tmp$
vivek@nixcraft:/tmp$ bash hello.sh
Hello World
vivek@nixcraft:/tmp$
vivek@nixcraft:/tmp$ sh hello.sh
Hello World
vivek@nixcraft:/tmp$ cat hello.sh
#!/bin/bash
echo "Hello World"
vivek@nixcraft:/tmp$
```

Capacidades do Shell:

- comandos simples – navegar nos diretórios, executar programas, manipular arquivos.
- criação de scripts e o desenvolvimento de software
- Funciona como uma linguagem de programação, o shell permite criar funções, além das tradicionais FOR, IF, WHILE, etc.


O shell permite:

- manipulação e obtenção de dados de arquivos de texto com grande facilidade, rapidez
- poderosa ferramenta para a bioinformática
- eficiente para lidar com grande volume de dados

O shell permite:

- manipulação e obtenção de dados de arquivos de texto com grande facilidade, rapidez
- poderosa ferramenta para a bioinformática
- eficiente para lidar com grande volume de dados

Exemplo: tentar abrir um arquivo grande utilizando o excel.



Prática: comandos básicos

entrem no site:

<https://www.bioinfodiscentes.com.br/>

Aulas e cursos > Cursos Ministrados > Introdução à Bioinformática > 1 - Linux e Shell

BAIXAR Pratica_Shell.zip na pasta de Downloads

This site was designed with the **WIX**.com website builder. Create your website today. [Start Now](#)

Biscentes - PPG de Bioinformática

[Página inicial](#) [Notícias](#) [O PPG](#) [Eventos](#) [Lojinha](#) [Aulas e cursos](#) [Softwares e Scripts](#)

1 - Bancos de Dados Biológicos	me	Aug 8, 2019
9 - Biologia de Sistemas	me	Jul 30, 2019
8 - LINUX e SHELL para Bioinformática	me	Jul 30, 2019
7 - Python	me	Jul 30, 2019

[link](#) para terminal online.

Introdução à Programação em R

Introdução à Bioinformática ●

Introdução à Programação R ○

Introdução ao LaTeX ○

Ementa: Contextualização da bioinformática na ciência, Linux e Shell para bioinformática, bancos de dados, montagem genômica,


Prática: comandos básicos

Abra o terminal

Prática: comandos básicos

Abra o terminal

Onde eu estou? Qual pasta? O que tem nela? ~~Quem sou eu?~~




Prática: comandos básicos

terminal

Onde eu estou? Qual pasta? O que tem nela?

> pwd



```
bash | 12 — Konsole
Arquivo  Editar  Exibir  Favoritos  Configurações  Ajuda
cpperico@macalan:~$ pwd
/home/ppginf/cpperico
cpperico@macalan:~$
```


Prática: comandos básicos

terminal

Onde eu estou? Qual pasta? O que tem nela?

```
> pwd
```

```
> ls
```



```
bash | 12 — Konsole
Arquivo  Editar  Exibir  Favoritos  Configurações  Ajuda

cpperico@macalan:~$ pwd
/home/ppginf/cpperico
cpperico@macalan:~$ ls
Bohm      Mailbox  R        public_html
Documentos Modelos  Softwares 'Área de Trabalho'
Downloads Música   Vídeos
Imagens   Público acesso.dat
cpperico@macalan:~$
```

Prática: comandos básicos

Me movendo entre pastas:

```
> cd Downloads/
```

```
> ls
```

```
cppperico@macalan:~$ pwd
/home/ppginf/cppperico
cppperico@macalan:~$ ls
Bohm          Mailbox      R            public_html
Documentos    Modelos     Softwares   'Área de Trabalho'
Downloads     Música      Vídeos
Imagens       Público     acesso.dat
cppperico@macalan:~$ cd Downloads/
cppperico@macalan:~/Downloads$ ls
Pratica_Shell.zip
cppperico@macalan:~/Downloads$
```

ATENÇÃO PARA DICA DE SUCESSO! TAB É VIDA! = autocompleta



POSITIVO



Prática: comandos básicos

Me movendo entre pastas:

```
> cd Downloads/
```

```
> ls
```

```
cppperico@macalan:~$ pwd
/home/ppginf/cppperico
cppperico@macalan:~$ ls
Bohm          Mailbox      R            public_html
Documentos    Modelos     Softwares   'Área de Trabalho'
Downloads     Música      Vídeos
Imagens       Público     acesso.dat
cppperico@macalan:~$ cd Downloads/
cppperico@macalan:~/Downloads$ ls
Pratica_Shell.zip
cppperico@macalan:~/Downloads$
```

Prática: comandos básicos

Vão para a pasta Downloads, onde está o .zip

```
> unzip Pratica_Shell.zip
```

```
cpperico@macalan:~/Downloads$ ls
Pratica_Shell.zip
cpperico@macalan:~/Downloads$ unzip Pratica_Shell.zip
Archive:  Pratica_Shell.zip
  creating: Exemplos/
  inflating: Exemplos/MultiTt.fasta
  inflating: Exemplos/Tt.fasta
  inflating: Exemplos/conteudoGC.sh
  inflating: Exemplos/simples.sh
  creating: Exemplos/genbank/
  inflating: Exemplos/genbank/002.genbank
  inflating: Exemplos/genbank/001.genbank
  inflating: Exemplos/genbank/004.genbank
  inflating: Exemplos/genbank/006.genbank
  inflating: Exemplos/genbank/003.genbank
  inflating: Exemplos/genbank/005.genbank
cpperico@macalan:~/Downloads$
```

Prática: comandos básicos

```
> cd Exemplos  
> ls
```

```
cpperico@macalan:~/Downloads$ cd Exemplos/  
cpperico@macalan:~/Downloads/Exemplos$ ls  
MultiTt.fasta  conteudoGC.sh  simples.sh  
Tt.fasta       genbank  
cpperico@macalan:~/Downloads/Exemplos$
```

Conteúdo da pasta Exemplos:

conteudoGC.sh [genbank](#) MultiTt.fasta simples.sh Tt.fasta

Conteúdo da pasta Exemplos:

conteudoGC.sh [genbank](#) MultiTt.fasta simples.sh Tt.fasta

Arquivos .FASTA

Armazenamento de sequências
biológicas:

nucleotídeos (ATGC) ou
proteínas (aminoácidos)

FORMATO:

> [cabeçalho](#)

[ATCG](#)

.. ou ..

[ABCDEFGHIKLM...](#)

Multifasta - arquivo com vários fasta

Conteúdo da pasta Exemplos:

conteudoGC.sh [genbank](#) MultiTt.fasta simples.sh Tt.fasta

Arquivos .FASTA

Armazenamento de sequências

biológicas:

nucleotídeos (ATGC) ou

proteínas (aminoácidos)

FORMATO:

> [cabeçalho](#)

[ATCG](#)

.. ou ..

[ABCDEFGHIKLM...](#)

Multifasta - arquivo com vários fasta

```
>gi|5524211|gb|AAD44166.1| cytochrome b [Elephas maximus maximus]
CTCCTGCCCCCGGCCTTGCCCGCCCGGCCCTGGGGGTCTCCCGGCCACCCTCCGGCGCTACGCCGCCCTGTGGGAGCG
GTTGGTAGGTCCCCTGCCCCGGGATCCCCGGGGGGACGGCTCTGGCCCAAGGAGGCCCTGGCCCCGCTCCGGGCGGCC
GGGAGGCCACCTGCGGGAAGGCCTCCCCCTGGAGGAGGCCCTGGCCCGGTCCAGGGAGACTTCCCGGCCCTCGCCCTC
CCCTCCGAGGGGAGGCCCTGGCCCTCCTCCGGGCCCTGGCCGAGCGGCTGGAGCGGTGGAGGGGAGCTAAGGGCCCT
GCGGGAGGAGAAGCCCCGCTCCGGGAGGCCCTGAAGGCCCTGGAGCCCCCGGAGGCGGCCCTGGTGGCGTTCTGGG
GGCATTGACCTGGGGACTACCGCTTGGTCCCGGGGCTTGTCGCTAGAATGGGGGGCATGAATGAAACAGACCTCGGCCGG
GTTAACCGCCGAGGCCTCTCCTCCCCAGGAGGCCTCCATCCT
```

Vamos ver na tela o conteúdo do
arquivo:

```
> cat Tt.fasta
```

Vamos ver na tela o conteúdo do arquivo:

```
> cat Tt.fasta
```

```
> clear
```

```
> head Tt.fasta
```

Agora sei quem estou olhando.

Vamos ver na tela o conteúdo do arquivo:

```
> cat Tt.fasta
```

```
> clear
```

```
> head Tt.fasta
```

Agora sei quem estou olhando.
E se eu quiser ver só o final do arquivo?

```
> tail Tt.fasta
```

Vamos ver na tela o conteúdo do arquivo:

```
> cat Tt.fasta
```

```
> clear
```

```
> head Tt.fasta
```

Agora sei quem estou olhando.
E se eu quiser ver só o final do arquivo?

```
> tail Tt.fasta
```

E se eu não souber como usar dado comando?

Vamos ver na tela o conteúdo do arquivo:

```
> cat Tt.fasta  
  
> clear  
> head Tt.fasta
```

Agora sei quem estou olhando.
E se eu quiser ver só o final do arquivo?

```
> tail Tt.fasta
```

E se eu não souber como usar dado comando?

```
> man tail  
> tail --help  
> wget -h
```

Vamos ver na tela o conteúdo do arquivo:

```
> cat Tt.fasta
```

```
> clear
```

```
> head Tt.fasta
```

Agora sei quem estou olhando.
E se eu quiser ver só o final do arquivo?

```
> tail Tt.fasta
```

E se eu não souber como usar dado comando?

```
> man tail
```

```
> tail --help
```

```
> wget -h
```


Mas eu quero varrer o arquivo, não só pegar o começo ou o fim dele...

```
> more Tt.fasta
```

```
> less Tt.fasta
```

TATABOX

-35 e -10: sequências onde se liga a RNAPolimerase → transcrição



Fonte: https://www.mun.ca/biology/scarr/MGA2_03-09.html

GREP E EXPRESSÕES REGULARES

Tenho o genoma completo do
Thermus thermophilus no arquivo
Tt.fasta.

Quero buscar a sequência TATAAT

> grep 'TATAAT' Tt.fasta

```
camila@Plutao:~/UFPR/MESTRADO/SemanaBioq2019/Bash> grep 'TATAAT' Tt.fasta
GCCTTCGGTATAATCCCCCATGCTCACC GTGGACCTTTCGGGCAAAAAGGCCCTGGTCATGGGGGTACCAACACGCGG
GCAGGGCCGGCTAAGCGGTGGACAACCTCTCCCTTGGCTATAATCACAAAGGCTATTGGGCGCTAGCTCAGCTGGC
TCCCACCACGATCAGTCCCACATACCGCCCTAGTATAATCGGCCCCGATGCTCTTGGACGACCGCTACCCCGTTCTG
TGGGGAAGGAGCTTTTGCTCTTCGGGGCAAGCCCCCTGGTACGACCTTTGAACCGGGTATAATGTCCCCAACCTTATG
CGCAAGGGGTATAATCCCCCATGGAGGCTTAAAGATCGCCCTCTTGGGGGCGGCACCGTGGGGAGCGCTTCTACAA
GAGGAGGAGAAGCCAGAGGACCACCGCCCCATCTTACCGGCTTCTCTGCTATAATGGGGCGGATTGGATAAGGTTTTCT
CGGTGCTATAATGGAAGACGGGCTCTAAACGCCCTCTAGGAGCGCTATGGCCAGGTAAGTCTGAGAAATCACCGAGG
GCCACAGCGACGCCGTTTGGCGCTTCTCCTCATGCGCGATTTCACCGGCTATAATCGCCCTATGGTGAGCACCTCTC
GGGGCTGAATAGAGGTCGAGAGGTCCTCATTCATGGGAGCCAGTATAATGGCGGATAATGCTTCTTTGCTTTGTGGAC
CACGCTTTTTACGAAGAGGCATAAAGCGTATAATCGGGCATGCTGGAAACCGCCCTGCGCCCGGAGGACCGGAAA
TACGAGAAGGTGGGCAAGAGGCTCGGTATAATCCGCTAAGATGCTCTTCTCCTCTCCCTACCCCTACGGCTCCGGGCG
GAGAAGGCCAAGGTATAATCCGCTCAAGGAGCGGCGATGCGGCTTTCGCCATAAGGCTTCGCCCGCTGGTGGCG
GATTTTGGCGCCGGGGGAAGGCCCGCTCAAGGACGGAGGCGGTATAATCGGCAACCGTGTGGTCTGCGCCCGCTC
GTAGGCCATTAACCTTACCGTGAGCCCTCTATAATCAGGGGCATGAACCTTCCGAGGACGCGGCTCTGGTGGACCCC
CCAGCAGGACGTAAGGTAGCCCATGGGCCAAGTGTATAATCGGGCCAGAGGTTATTGGAGGCTTTATGGAGTGCGTAC
GCCCTTCTAAGGATAGAGGCCAAGTACCGGGCTGGCTATAATGGACCAATGAGCGTCTTACGAGCTTTACCGGAAA
GCCCTAAAGGAGCGGGGAAGTCTCACCTACACCTGCGGCCGGAAGCCCTACCGAGGAGCGGAAGGCGCTTTTATAAT
GTAGCGAAGGTTCTTTTGGGACATTTGGACGGGTACACCGTTTCAGCGAGGTGCTATAATGCCTTTGTCGGACCT
TGTGATCTCTGACGGGCCCTTGATACAGCTATCCCCCTGGCTCCTCGTTGCTCTTGTATAATCTCCCGCAACAG
camila@Plutao:~/UFPR/MESTRADO/SemanaBioq2019/Bash> |
```

GREP

Mas onde está a sequência que encontrei??

Agora tenho a linha

```
> grep -n 'TATAAT' Tt.fasta
```

```
camila@Plutao:~/UFPR/MESTRADO/SemanaBioq2019/Bash> grep -n 'TATAAT' Tt.fasta
3639:GCCTTCGGTATAATCCCCCATGCTCACCGTGGACCTTTGCGGCAAAAAGGCCCTGGTCATGGGGGTACCAACGACGCG
3788:GCAGGGCCGGCTAAGCGGTGGACAACCTCTCCCTTGGCCATAATGAGGCTATTGGGCCGTTAGCTCAGCTGGC
4421:TCCACACGATCAGTCCCACATACCGCCCGTAGATAATCGGCCCCGATGCTCTTGGACGACCGCTACCCCGTCTG
4636:TGGGAAGGAGCTTTTGCTCTCCGGGCAAGCCCCCTGGTACGACCTTTGAACGGGTATAATGTCCCAACCTTAG
5720:CGCAAGGGGTATAATCCCCCATGGAGGCTTAAAGATCGCCCTCTTGGGGGGCGGACCGTGGGAGCGCCTCTACAA
6589:GAGGAGGAGAAGCCAGAGGACACCGCCCCATCTTACGGCCTTCTGCTATAATGGGGCGGATTGGATAAGGTTTTC
16183:CGGTGCTATAATGGAAGACGGCGTCTAAAGCCTTCTAGGAGCGCTATGGCCAGGTAAGTGCCTGTAGAAATCACCAGG
18117:GCCCAGGCGAGCCCGGTTTGCGCCTTCTCCCTCATGCGCGATTTTACCGGCTATAATCGCCCTATGGTGAGCACCTC
18230:GGGGCTGAATAGAGGTGAGAGGTCCTTCCATGGGAGCCAGTATAATGGCGGATAATGCTTCTTGTGTTGTGGAC
18517:CACGCTTTTTCACGAAGAGGCATAAAGCGTTATAATCGGGCCATGCTGGAAACCGCCCTGCGCCCGGAGGACCGGAAA
18829:TACGAGAAGGTGGGCAAGAGGCTCGGTATAATCCGCTCAAGGAGCGGCGATGCGGCTTTGCGCCATAAGGCCCTCGCCCCCTGGTGCG
19007:GAGAAGCGGCAAGGTATAATCCGCTCAAGGAGCGGCGATGCGGCTTTGCGCCATAAGGCCCTCGCCCCCTGGTGCG
19184:GATTTTGCGCCGGGGGAAGGCCCGTCAAGGAGCGGAGCGGCTATAATCGGCAACCGTGTGCTGCGCCGCCGCTC
19217:GTGAGGCCATTAACTTACCCGTGAGCCCTTATAATCAGGGGCATGAACCTTCCGAGGACGCGGCTCTGGTGGAACCC
19698:CCAGCAGGACGTAAAGGTAGCCATGGGCGAAGTATAATCGGCCAGAGGTTATTGGAGGCTTTATGGAGTGCGTAC
20347:GCCCTTCTAAGGATAGAGGCCAAGTACCGGCCCTGGCTATAATGGACCAATGAGCGTCTTGACGAGCTTTACCGGAAA
20979:GCCCTAAAGGAGCGGGAAGTCTCACCTACACCTGGCCCGGAAAGCCCTACCCGAGGAGCGGGAAGGCGCTTTATAAT
24923:GTAGCGAAGGTTCTTTTGGAGCACATTTGGACGGGTACACCGTTTACGCGAGGTGCTATAATGCCTTTGTCCGACCT
25019:TGTGATCTGACGCGGCCCTTGTATACGCTATCCCCCTGGCCTCCTCGTTGCTTGTATAATCCTCCCGCAACAG
camila@Plutao:~/UFPR/MESTRADO/SemanaBioq2019/Bash>
```

Dica de Ouro

Use a setinha para cima para recuperar o último comando histórico todo de comandos é salvo

> `history`



GREP

Mas onde está a sequência que encontrei??

Agora tenho a linha

```
> grep -n 'TATAAT' Tt.fasta
```

```
camila@Plutao:~/UFPR/MESTRADO/SemanaBioq2019/Bash> grep -n 'TATAAT' Tt.fasta
3639:GCCTTCGGTATAATCCCCCATGCTCACCGTGGACCTTTGCGGCAAAAAGGCCCTGGTCATGGGGGTACCAACGACGCG
3788:GCAGGGCCGGCTAAGCGGTGGACAACCTCTCCCTTGGCCATAATGAGGCTATTGGGCCGTTAGCTCAGCTGGC
4421:TCCACACGATCAGTCCACATACCGCCCGTAGTATAATCGGCCCCGATGCTCTTGGACGACCGCTACCCCGTCTG
4636:TGGGAAGGAGCTTTTGCTCTCCGGGCAAGCCCCCTGGTACGACCTTTGAACGGGTATAATGTCCCAACCTTAG
5720:CGCAAGGGGTATAATCCCCCATGGAGGCTTAAAGATCGCCCTCTTGGGGGGCGGACCGTGGGAGCGCCTCTACAA
6589:GAGGAGGAGAAGCCAGAGGACACCGCCCCATCTTACGGCCTTCTGCTATAATGGGGCGGATTGGATAAGGTTTTC
16183:CGGTGCTATAATGGAAGACGGCGTCTAAAGCCTTCTAGGAGCGCTATGGCCAGGTAAGTGCCTGTAGAAATCACCAGG
18117:GCCCCAGCGCAGCCCGGTTTGCGCCTTCTCCCTCATGCGCGATTTTACCGGCTATAATCGCCCTATGGTGAGCACCTC
18230:GGGGCTGAATAGAGGTGAGAGGTCCATTCCATGGGAGCCAGTATAATGGCGGATAATGCTTCTTGTGTTGTGGAC
18517:CACGCTTTTTCACGAAGAGGCATAAAGCGTTATAATCGGGCCATGCTGGAAACCGCCCTGCGCCCGGAGGACCGGAAA
18829:TACGAGAAGGTGGCAGAGGCTCGGTATAATCCGCTCAAGGAGCGGCGATGCGGCTTTGCGCCATAAGGCCCTCGCCCCCTGGTGCG
19007:GAGAACGGCCAAGGTATAATCCGCTCCAGGAGCGGCGATGCGGCTTTGCGCCATAAGGCCCTCGCCCCCTGGTGCGG
19184:GATTTTGCGCCGGGGGAAGGCCCGTCAAGGAGCGGAGCGGCTATAATCGGCAACCGTGTGCTGCGCCGCCGCTC
19217:GTGAGGCCATTAACTTACCCGTGAGCCCTTATAATCAGGGGCATGAACCTTCCGAGGACGCGGCTCTGGTGGAACCC
19698:CCAGCAGGACGTAAAGGTAGCCATGGGCCAAGTGTATAATCGGCCAGAGGTTATTGGAGGCTTTATGGAGTGCGTAC
20347:GCCCTTCTAAGGATAGAGGCCAAGTACCGGCTGGCTATAATGGACCAATGAGCGTCTTGACGAGCTTTACCGGGA
20979:GCCCTAAAGGAGCGGGAAGTCTCACCTACACCTGGCCCGGAAGGCCCTACCCGAGGAGCGGAAGGCGCTTTATAAT
24923:GTAGCGAAGGTTCTTTTGGAGCACATTTGGACGGGTACACCGTTTACGCGAGGTGCTATAATGCCTTTGTCCGACCT
25019:TGTGATCTGACGCGGCCCTTGTATACGCTATCCCCCTGGCCTCCTCGTTGCTTGTATAATCCTCCCGCAACAG
camila@Plutao:~/UFPR/MESTRADO/SemanaBioq2019/Bash>
```

E se minha sequência não for bem definida?
por exemplo TTCG A ou T GAAG A ou C

E se minha sequência não for bem definida?
por exemplo TTCG A ou T GAAG A ou C

```
> grep -n 'TTCG[AT]GAAG[AC]' Tt.fasta
```

```
camila@Plutao:~/UFPR/MESTRADO/SemanaBioq2019/Bash> grep -n 'TTCG[AT]GAAG[AC]' Tt.fasta
1048: TGATAAGATGGGCGGGAAATGAGGCCGCCCTTTGGGGCTTTGGGGACCGGCTTCGTGAAGAAAGGCACGAAAGGAGGG
7589: CCCTGGCGAGGCGCGAAGGGATCCCCATCCACACCTTCATGCTCGCCCGGAGCCCGAACTCCTCGCCTTCGTGAAGAAG
7600: CTCGGGGGTCAAGTTGAGCCGTTCGTGAAGACCGGCCAAGAGGTGGGTGAGCGCGTGCCGAAGGCCCTCGGCCCCAAGG
18344: CACGGGACGGATGGCGTGTTTCGTGAAGAAACAAGAGCGGCCGTGGCCTCGCGGCCCTCGGGACTTTCGCCCAGAACC
camila@Plutao:~/UFPR/MESTRADO/SemanaBioq2019/Bash> █
```

E se minha sequência não fôr bem definida?
por exemplo TTCG A ou T GAAG A ou C

```
> grep -n 'TTCG[AT]GAAG[AC]' Tt.fasta
```

```
camila@Plutao:~/UFPR/MESTRADO/SemanaBioq2019/Bash> grep -n 'TTCG[AT]GAAG[AC]' Tt.fasta
1048: TGATAAGATGGGCGGGAAATGAGGCCGCCCTTTGGGGCTTTGGGGACCGGCTTCGTGAAGAAAGGCACGAAAGGAGGG
7589: CCCTGGCGAGGCGCGAAGGGATCCCCATCCACACCTTCATGCTCGCCCGGAGCCCGAACTCCTCGCCTTCGTGAAGAAG
7600: CTCGGGGGTCAAGTTGAGCCGTTCGTGAAGACCGGCCAAGAGGTGGGTGAGCGCGTGCCGAAGGCCCTCGCCCCCAAGG
18344: CACGGGGACGGATGGCGTGTTTCGTGAAGAAACAAGAGCGGCCGTGGCCTCGCGGCCTCGGGGACTTCGCCCCAGAACC
camila@Plutao:~/UFPR/MESTRADO/SemanaBioq2019/Bash> █
```

E se eu quiser salvar esse resultado?

E se minha sequência não fôr bem definida?
por exemplo TTCG A ou T GAAG A ou C

```
> grep -n 'TTCG[AT]GAAG[AC]' Tt.fasta
```

```
camila@Plutao:~/UFPR/MESTRADO/SemanaBioq2019/Bash> grep -n 'TTCG[AT]GAAG[AC]' Tt.fasta
1048: TGATAAGATGGGCGGGAAATGAGGCCGCCCTTTGGGGCTTTGGGGACCGGCTTCGTGAAGAAAGGCACGAAAGGAGGG
7589: CCCTGGCGAGGCGCGAAGGGATCCCCATCCACACCTTCATGCTCGCCCGGAGCCCCGAACCTCTGCCCTTCGTGAAGAAG
7600: CTCGGGGGTCAAGTTGAGCCGTTCGTGAAGACCGGCCAAGAGGTGGGTGAGCGCGTGGCCGAAGGCCCTCGGCCCCAAGG
18344: CACGGGACGGATGGCGTGTTTCGTGAAGAAACAAGAGCGGCCGTGGCCCTCGGCGGCTTCGGGGACTTCGCCCCAGAACC
camila@Plutao:~/UFPR/MESTRADO/SemanaBioq2019/Bash> █
```

E se eu quiser salvar esse resultado?
Posso direcionar a saída (print na tela) para um arquivo usando >

```
> grep -n 'TTCG[AT]GAAG[AC]' Tt.fasta > seqs.txt
> cat seqs.txt
```

Ainda não entendi porque estou aprendendo a usar o terminal?

Irão haver diversas situações em que saber usar o terminal será vital!

Ainda não entendi porque estou aprendendo a usar o terminal?

Irão haver diversas situações em que saber usar o terminal será vital!
Por exemplo: quero rodar um BLAST das minhas sequências.

Ainda não entendi porque estou aprendendo a usar o terminal?

Irão haver diversas situações em que saber usar o terminal será vital!
Por exemplo: quero rodar um BLAST das minhas sequências.

Mas o que é BLAST?

Basic Local Alignment Search Tool: algoritmo que compara/alinha sequências de nt e aa.

Ainda não entendi porque estou aprendendo a usar o terminal?

Irão haver diversas situações em que saber usar o terminal será vital!
Por exemplo: quero rodar um BLAST das minhas sequências.

Mas o que é BLAST?

Basic Local Alignment Search Tool: algoritmo que compara/alinha sequências de nt e aa.

Quando uso o BLAST?

- Quero verificar em diferentes organismos se possuem dada sequência em comum.
- Ou identificar a possível função de dada proteína com base na função de proteínas similares em diferentes organismos.

...e isso tudo é possível fazer facilmente online

Ainda não entendi porque estou aprendendo a usar o terminal?

Irão haver diversas situações em que saber usar o terminal será vital!
Por exemplo: quero rodar um BLAST das minhas sequências.

Mas o que é BLAST?

Basic Local Alignment Search Tool: algoritmo que compara/alinha sequências de nt e aa.


Quando uso o BLAST?

- Quero verificar em diferentes organismos se possuem dada sequência em comum.
- Ou identificar a possível função de dada proteína com base na função de proteínas similares em diferentes organismos.

... e isso tudo é possível fazer facilmente online

E quando uso o BLAST no terminal?

No próprio site do NCBI-BLAST citam alguns casos:




The screenshot shows the NCBI BLAST website. The top navigation bar includes links for NIH (U.S. National Library of Medicine) and NCBI (National Center for Biotechnology Information), along with a 'Sign in to NCBI' link. The main heading is 'BLAST®' with a 'Download BLAST Software and Databases' link. Below this, there is a section titled 'BLAST+ executables' with a paragraph of text: 'Do you have difficulties running high volume BLAST searches? Do you have proprietary sequence data to search and cannot use the NCBI BLAST web site? Do you have access to your own server? Do you have your own research pipeline? Have security or IP concerns about sending searches outside of your organization? If you answered yes to any of these questions, read on!'. A second paragraph states: 'The NCBI provides a suite of command-line tools to run BLAST called BLAST+. This allows users to perform BLAST searches on their own server without size, volume and database restrictions. BLAST+ can be used with a command line so it can be integrated directly into your workflow.'

- Dificuldade em rodar grande nº de BLASTs
- Tenho sequências próprias que não estão no banco de dados
- Tenho meu próprio servidor
- Tenho meu pipeline

Manual online do BLAST de terminal

<https://www.ncbi.nlm.nih.gov/books/NBK279690/>



BLAST® Command Line Applications User Manual [Internet].

[< Prev](#)[Next >](#)[▶ Show details](#)[Contents](#) ▼

Quick start

Estimated reading time: 2 minutes

A BLAST search against a database requires at least a `-query` and `-db` option. The command:

```
blastn -db nt -query nt.fsa -out results.out
```

will run a search of `nt.fsa` (a nucleotide sequence in FASTA format) against the `nt` database, printing results to the file `results.out`. If “`-out results.out`” had been left off, the results would have been printed to `stdout` (i.e., the screen). The `blastn` application searches a nucleotide query against a nucleotide database.

To send the search to our servers and databases, add the `-remote` option:

Exercício - conteúdo GC – brincando um pouco mais com o terminal

Tenho uma sequência fasta e quero descobrir o conteúdo GC dela.

Exercício - conteúdo GC – brincando um pouco mais com o terminal

Tenho uma sequência fasta e quero descobrir o conteúdo GC dela.

1) Quero apenas as bases G e C da minha sequência.

```
> grep -o '[GC]' Tt.fasta
```

-o = imprimir somente os termos correspondentes, C ou G (1 por linha)

Exercício - conteúdo GC – brincando um pouco mais com o terminal

Tenho uma sequência fasta e quero descobrir o conteúdo GC dela.

1) Quero apenas as bases G e C da minha sequência.

```
> grep -o '[GC]' Tt.fasta
```

-o = imprimir somente os termos correspondentes, C ou G (1 por linha)

2) Agora preciso contar as ocorrências de G e C. Para isso uso wc. Passo a saída da 1ª parte para a 2ª parte do comando com o |.

```
> grep -o '[GC]' Tt.fasta | wc -l
```

-l = conte o número de linhas

... Exercício - conteúdo GC

Agora sei quantos G e C existem na sequência. Mas não sei o tamanho da sequência...

3) Para isso basta contar o número de caracteres da sequência toda (sem o cabeçalho)

```
> grep '[ATCG]' Tt.fasta | wc -m
```

-m = conte o número de caracteres

... Exercício - conteúdo GC

Agora sei quantos G e C existem na sequência. Mas não sei o tamanho da sequência...

3) Para isso basta contar o número de caracteres da sequência toda (sem o cabeçalho)

```
> grep '[ATCG]' Tt.fasta | wc -m
```

-m = conte o número de caracteres

Sei o número de GC (1470577) e na sequência completa (2116059), logo
o **%GC = 69%**

Shell Scripts

Mas... E se eu errar algo tenho de começar do zero?

Tenho que repetir certo conjunto de comando várias vezes... Isso dá muito trabalho...

Shell Scripts

Mas... E se eu errar algo tenho de começar do zero?

Tenho que repetir certo conjunto de comando várias vezes... Isso dá muito trabalho...

Para isso existem os scripts.

São um arquivo que contém uma sequência de comandos que poderiam ser digitados em sequência no prompt.

Facilitam na automatização de tarefas repetitivas.

Shell Scripts

Mas... E se eu errar algo tenho de começar do zero?

Tenho que repetir certo conjunto de comando várias vezes... Isso dá muito trabalho...

Para isso existem os scripts. São um arquivo que contém uma sequência de comandos que poderiam ser digitados em sequência no prompt. Facilitam na automatização de tarefas repetitivas.

Os arquivos script começam sempre com `#!/bin/bash`

A extensão padrão é `.sh`

Pode-se fazer comentários no código usando `#` (texto ignorado pelo sistema)

Shell Scripts

Mas... E se eu errar algo tenho de começar do zero?

Tenho que repetir certo conjunto de comando várias vezes... Isso dá muito trabalho...

Para isso existem os scripts. São um arquivo que contém uma sequência de comandos que poderiam ser digitados em sequência no prompt. Facilitam na automatização de tarefas repetitivas.

Os arquivos script começam sempre com `#!/bin/bash`

A extensão padrão é `.sh`

Pode-se fazer comentários no código usando `#` (texto ignorado pelo sistema)

Podemos fazer então um script calculador de %GC

script conteúdo GC

Script pronto no arquivo `conteudoGC.sh`

```
#!/bin/bash

# Comentários:
# Este script fornece o percentual do conteúdo GC de uma sequência fasta.
# Para utilizar este script, use o formato a seguir:
# ./conteudoGC meuarquivo.fasta

# obter o número de G e C na sequência
GC=$(grep '^[>]', $1 | grep -o '[GC]' | wc -l)

# obter o número de A e T na sequência
AT=$(grep '^[>]', $1 | grep -o '[AT]' | wc -l)

# soma AT com GC, dando o número de bases total
tot=$((GC+$AT))

# dá a porção inteira do percentual
echo $((GC*100/$tot))
```

script conteúdo GC

Script pronto no arquivo `conteudoGC.sh`

```
#!/bin/bash

# Comentários:
# Este script fornece o percentual do conteúdo GC de uma sequência fasta.
# Para utilizar este script, use o formato a seguir:
# ./conteudoGC meuarquivo.fasta

# obter o número de G e C na sequência
GC=$(grep '^[>]', $1 | grep -o '[GC]' | wc -l)

# obter o número de A e T na sequência
AT=$(grep '^[>]', $1 | grep -o '[AT]' | wc -l)

# soma AT com GC, dando o número de bases total
tot=$((GC+$AT))

# dá a porção inteira do percentual
echo $((GC*100/$tot))
```

Para rodar:

```
> ls -lh
> chmod +x conteudoGC.sh
> ./conteudoGC.sh Tt.fasta
```

DÚVIDAS?



Contato

camilapp94@gmail.com

Programa de Pós-Graduação Associado em Bioinformática - UFPR



– FIM DO TERCEIRO ATO –

